Crawling

- requests
- BeautifulSoup
 - find / find_all
 - select_one / select

URL

- Uniform Resource Locator
- ① ② ③ ④ ⑤ ⑥
- https://news.naver.com:80/main/read.naver

```
⑦
?mode=LSD&mid=shm&sid1=105&oid=001&aid=0009847211
⑧
#da_727145
```

- 1) http:// or https:// Protocol
- 2 news Sub Domain
- 3 naver.com Domain
- ④:80 Port
- ⑤ /main/ Path
- 6 read.nhn Page
- ? mode=LSD&mid=shm&sid1=105&oid=001&aid=0009847211 Query String (Parameter)
- 8 #da_727145 Fragment

- Crawling
 - 조직적 / 자동화 된 방법으로 데이터를 탐색하거나 수집하는 것
 - 데이터 수집 절차
 - 원하는 URL에 request를 보내고 결과를 받아온다
 - 받은 결과물 (HTML / JSON / XML)을 파싱(Parsing)한다
 - 필요한 정보만 추출한다
 - 파이썬에서 크롤링을 하기 위해 필요한 라이브러리
 - 데이터 통신 : requests / urllib
 - 데이터 추출 : bs4 (BeautifulSoup)


- 웹 페이지의 종류
 - 정적 페이지
 - http://ggoreb.com/http/get/



- http://ggoreb.com/http/post/



- 동적 페이지
 - http://ggoreb.com/http/json/









- requests vs selenium
 - requests
 - 받아오는 문자열에 따라 두가지 방법으로 구분
 - html / xml : requests + BeautifulSoup
 - json : requests
 - selenium
 - 브라우저를 직접 열어서 데이터를 받는 방법
 - 웹 드라이버를 통해 브라우저를 제어
 - ※ 속도 순위

requests > requests + BeautifulSoup > selenium

ison

html / xml

브라우저 제어

- requests
 - 모듈 가져오기

```
import requests
```

● URL 호출 후 응답코드 확인

```
result = requests.get('http://ggoreb.com/http')
print(result.status_code)
```

200

● 응답결과 확인

```
print(result.text)
```

● Encoding 처리 (한글 깨짐)

```
result.encoding = 'utf-8'
print(result.text)
```

● 기본 사용법

```
import requests
res = requests.get('http://ggoreb.com/python/request.jsp')
print(res.status_code)
print(res.text)
```

200

```
method : GET<br>
query string<br>
<br><br><br>>
header(br>
key : accept, value : */*<br>
key : Accept-Encoding, value : gzip, deflate<br>
key : connection, value : close<br>
key : host, value : ggoreb.com<br>
key : HOSTING_CONTINENT_CODE, value : AS<br>
key : HOSTING_COUNTRY_CODE, value : KR<br>
key : HOSTING_WHITE_IP, value : false<br>
key : user-agent, value : python-requests/2.25.0 <br>
key : X-Forwarded-Proto, value : http<br>
key : X-SERVER_PORT, value : 80<br>
key : X-SERVER_PROTOCOL, value : HTTP/1.1<br>
key : X-SIMPLEXI, value : 110.70.51.5<br>
key : content-length, value : 0<br>
```

● Parameter 사용 (GET - **params**)

```
import requests
param = { 'page': 1, 'search': '검색어' }
res = requests.get(
   'http://ggoreb.com/python/request.jsp', params=param)
print(res.text)
method : GET<br>
query string<br>
key : search, value : 검색어<br>
key : page, value : 1<br>
<br><br>>
header<br>>
key : accept, value : */*<br>
key : Accept-Encoding, value : gzip, deflate, br<br>
key : connection, value : close<br>
key : host, value : ggoreb.com<br>
```

● Parameter 사용 (POST - <u>data</u>)

```
import requests
param = { 'page': 1, 'search': '검색어' }
res = requests.post(
   'http://ggoreb.com/python/request.jsp', data=param)
print(res.text)
method : POST<br>
query string<br>
key : search, value : 검색어<br>
key : page, value : 1<br>
<br><br>>
header<br>
key : accept, value : */*<br>
key : Accept-Encoding, value : gzip, deflate, br<br>
key : connection, value : close<br>
key : content-length, value : 41<br>
```

● Header 사용

```
import requests
header = { 'user-agent': 'android', 'accept-language': 'en' }
res = requests.get(
     'http://ggoreb.com/python/request.jsp', headers=header)
print(res.text)
method : GET<br>
query string<br>
header(br>
key : accept, value : */*<br>
key : Accept-Encoding, value : gzip, deflate<br>
key : accept-language, value : en<br>
key : connection, value : close<br>
key : host, value : ggoreb.com<br>
key : HOSTING CONTINENT CODE, value : AS<br>
key : HOSTING COUNTRY CODE, value : KR<br>
key : HOSTING_WHITE_IP, value : false<br>
key : user-agent, value : android<br>
```


● 요청 메소드 (GET / POST / PUT / DELETE)

```
import requests
res = requests.get(
     'http://ggoreb.com/http/method.jsp')
print(res.text)
                                 <h1>Method => <span style="color:blue;";GET(/span></h1>
import requests
res = requests.post(
     'http://ggoreb.com/http/method.jsp')
print(res.text)
                                <h1>Method => <span style="color:red;";POST(/span></h1>
import requests
res = requests.put(
     'http://ggoreb.com/http/method.jsp')
print(res.text)
                                  <h1>Method => <span style="color:green;" PUT //span></h1>
import requests
res = requests.delete(
     'http://ggoreb.com/http/method.jsp')
print(res.text)
                              <h1>Method => <span style="color:yellow;";DELETE(/span></h1>
```

● 데이터 추출하기

```
import requests
result = requests.get(
    'http://ggoreb.com/python/html/data1.html').text
s idx = 0
e idx = 0
while True:
    s idx = result.find('', e idx)
    if s_idx == -1:
        break
    e_idx = result.find('', s_idx)
    print(result[s_idx + 4 : e_idx])
```





■ 연습문제

● 결과와 같이 span의 숫자 내용만 출력하기

```
C ▲ 주의 요함 | view-source:ggoreb.com/python/html/number.html
                                                                      ④ 🖻 ☆ 🐂 🗊 📵 🚼
110 <body>
       <div class="win result">
111
           <h4><strong>1000회</strong> 당첨결과</h4>
112
           (2022년 01월 29일 추첨)
113
                                                                                                   1000회 당첨결과
114
           <div class="nums">
               <div class="num win">
115
                  <strong>당첨번호</strong>
116
117
                                                                                                     (2022년 01월 29일 추첨)
                      <span class="ball_645 lrg ball1">2</span>
118
                      <span class="ball 645 lrg ball1">8</span>
119
                      <span class="ball 645 lrg ball2">19</span>
                      <span class="ball 645 lrg ball3">22</span>
121
                      <span class="ball 645 lrg ball4">32</span>
122
                      <span class="ball 645 lrg ball5">42</span>
123
                  124
               </div>
125
               <div class="num bonus">
126
                                                                                                    당첨번호
                                                                                                                                          보너스
127
                  <strong>보너스</strong>
                  <span class="ball_645 lrg ball4">39</span>
128
              </div>
129
130
           </div>
131
132 </body>
```

```
import requests
address = 'http://ggoreb.com/python/html/number.html'
res = requests.get(address)
res.encoding = None # 한글 깨짐 처리
```

방법 1) 문자열을 찾아서 시작 인덱스로 방법 2) 정규식

■ 연습문제

● 결과와 같이 img의 src 속성 값 출력하기

```
→ C ⊙ 주의 요함 | view-source:ggoreb.com/python/html/attribute.html
  <html>
3 <head>
                                                                    ← → C ① 주의 요함 | ggoreb.com/python/html/attribute.html
4 <meta charset="utf-8">
5 <title>Insert title here</title>
6 </head>
  <body>
      <div class="info">
          <img src="/images/luffy.jpg" width="10%" title="루피">
          <img src="/images/nami.jpg" width="10%" title="나미">
         <img src="/images/robin.jpg" width="10%" title="로빈">
          <img src="/images/zoro.jpg" width="10%" title="조로">
12
      </div>
13
14 </body>
  </html>
```

```
import requests
address = 'http://ggoreb.com/python/html/attribute.html'
res = requests.get(address)
res.encoding = None # 한글 깨짐 처리
```